MACHINE LEARNING II · 2026/27 · TURMA PL3 · GRUPO 08

Deteção de sopros cardíacos com uma CNN e uma RNN

Uma previsão por criança (Present / Unknown / Absent) a partir de gravações do coração do dataset CirCor DigiScope

Afonso Miguel Vieira Marcos (202404088) · Pedro Miguel Moreira Pereira Afonso (202404125) · Rafael Arruda Costa (202300278)

O PROBLEMA

Uma previsão por criança, numa métrica que pesa os erros de forma diferente

PRESENT · PESO 5

Há um sopro audível. Falhar um destes é o erro mais grave.

UNKNOWN · PESO 3

O médico não conseguiu decidir (ruído, choro, má gravação).

ABSENT · PESO 1

Não há sopro. Um falso alarme custa pouco.

Weighted accuracy (WA) = (5 · acertos Present + 3 · acertos Unknown + acertos Absent) ÷ (5 · nº Present + 3 · nº Unknown + nº Absent), calculada **por paciente**.

PREVER SEMPRE ABSENT

0.39

PREVER SEMPRE PRESENT · O MÍNIMO A BATER

0.50

EDA · OS DADOS

942 crianças, 3163 gravações e classes muito desequilibradas

Pacientes por classe

Absent · 695 (74%)



Present · 179 (19%)



Unknown · 68 (7%)



AS GRAVAÇÕES

4 kHz, de 5 a 65 s, até 4 focos de auscultação por criança (aórtico, pulmonar, tricúspide, mitral).

O RÓTULO É DO PACIENTE

19% das gravações de crianças Present não têm sopro audível. Usamos o campo **Murmur locations** para dar a cada gravação o seu rótulo no treino.

EDA · ONDE ESTÁ O SOPRO

Os sopros estão na sístole, entre S1 e S2, e acima de 150 Hz

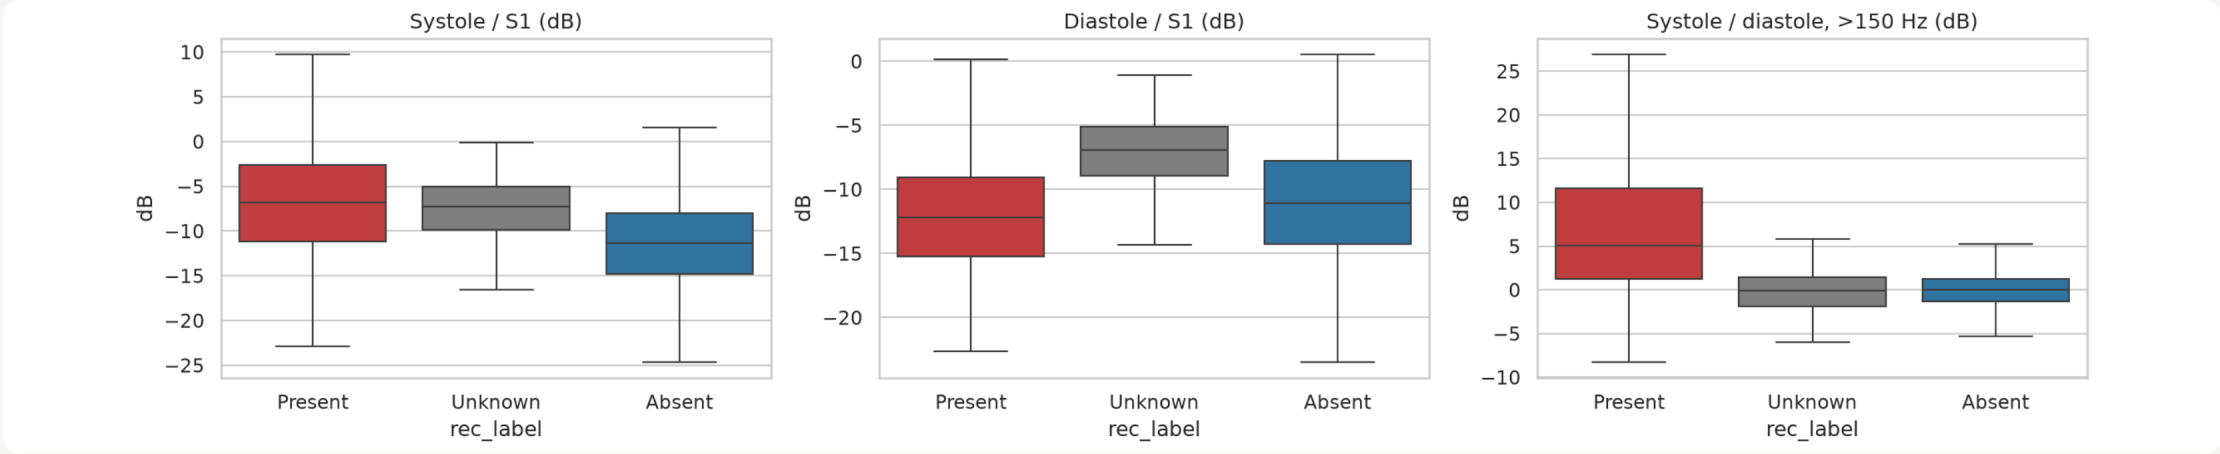


Gráfico da direita: com sopro, a sístole tem **~5 dB mais energia acima de 150 Hz** do que a diástole; sem sopro, ~0 dB.

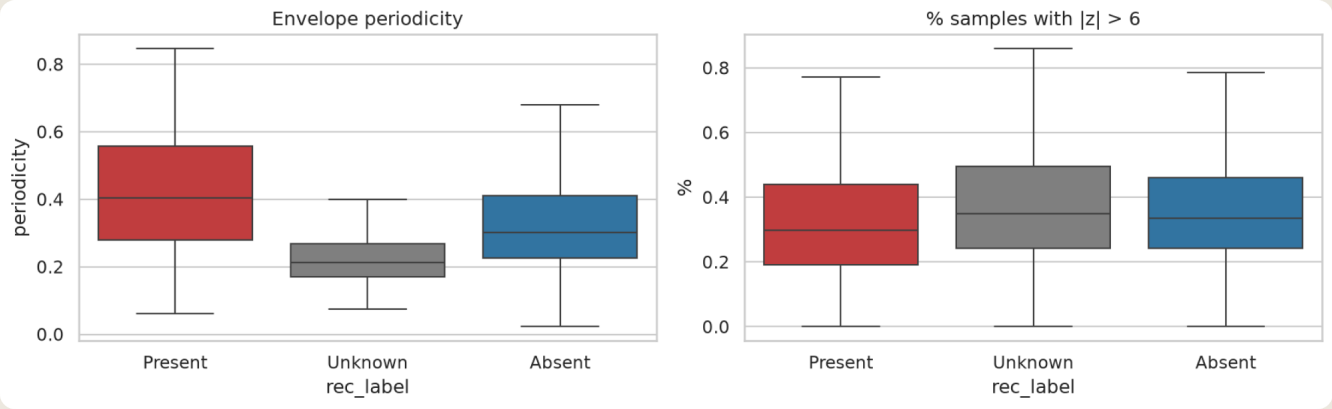
CONSEQUÊNCIA

O modelo tem de ver ciclos cardíacos completos com boa resolução no tempo.

Energia por fase do ciclo, medida com as segmentações manuais (.tsv), usadas só na EDA.

EDA · A CLASSE UNKNOWN

Unknown é sobretudo “má gravação”, não um som próprio



As gravações Unknown são as **menos periódicas**: o ritmo do coração quase não se vê, por causa de ruído, choro ou movimento.

CONSEQUÊNCIA

Não normalizar cada janela: o nível de ruído é informação útil para reconhecer o Unknown.

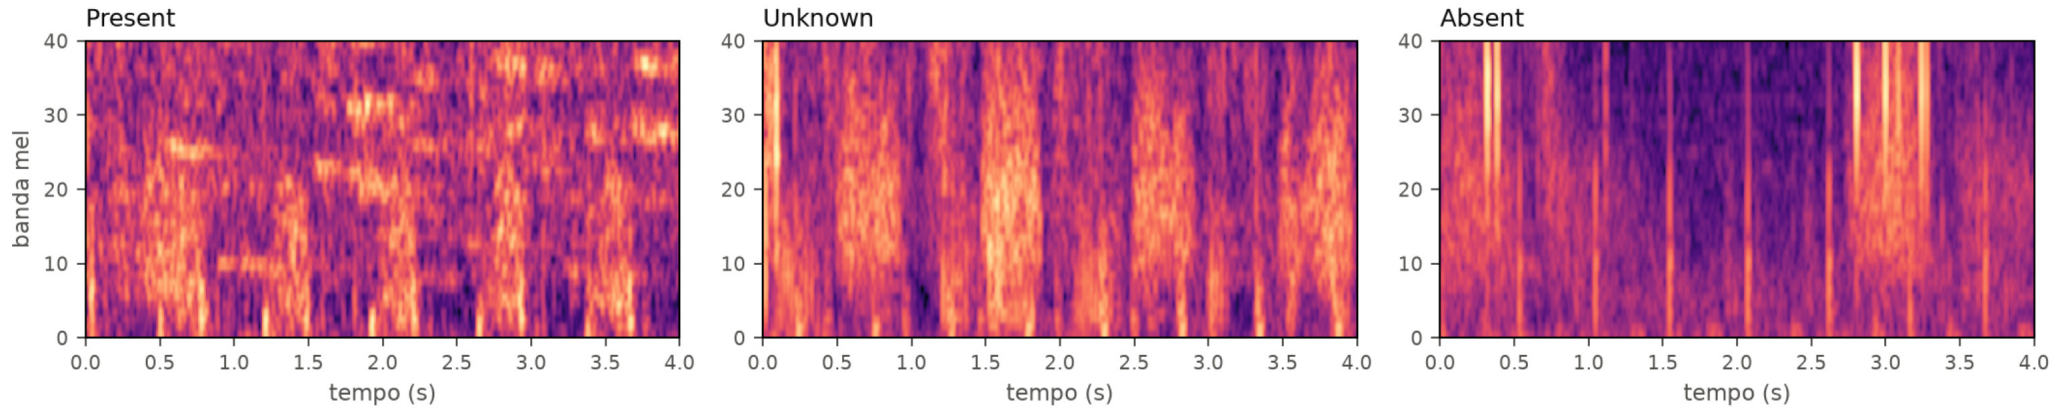
PRÉ-PROCESSAMENTO

Cada decisão vem de uma observação da EDA

Decisão	Porquê
Filtro passa-banda 25–1000 Hz e normalização da amplitude de cada gravação	abaixo de 25 Hz é movimento, acima de 1 kHz quase só ruído; o volume varia entre estetoscópios
Janelas de 4 s com passo de 2 s (31 409 janelas)	as gravações duram 5 a 65 s; 4 s contêm 3 a 7 ciclos cardíacos completos
Mel-espectrograma de 40 bandas × 401 frames (um a cada 10 ms)	10 ms chegam para separar S1, sístole e S2, onde está o sopro
Normalização por banda mel, com estatísticas só do treino	sem fuga de informação; não apaga o nível de ruído (Unknown)
Rótulo por gravação no treino, avaliação sempre por paciente	19% das gravações de crianças Present não têm sopro

A ENTRADA DOS DOIS MODELOS

O som passa a ser uma “imagem” de 40 × 401



PRESENT

manchas de energia entre os batimentos: o sopro

UNKNOWN

energia espalhada por todo o lado: ruído

ABSENT

riscos nítidos (S1 e S2) e silêncio entre eles

PROTOCOLO DE AVALIAÇÃO

Divisão por paciente, com o teste guardado até ao fim

Fold 0	Fold 1	Fold 2	Fold 3	Fold 4	Teste
151	151	150	151	150	189 pacientes

753 pacientes em validação cruzada (5 folds) · 189 de teste (20%) · estratificado pelas 3 classes

POR PACIENTE

Todas as gravações de uma criança ficam no mesmo fold. As 70 crianças gravadas em duas campanhas também.

SEM FUGA DE INFORMAÇÃO

Normalização calculada só no treino. Os limiares de cada fold são escolhidos nos outros 4.

TESTE AVALIADO UMA VEZ

Só no fim, com os modelos já congelados. Nunca usado para decidir nada.

CLASSIFICADOR 1 · CNN 2D

A CNN procura padrões locais na imagem do som

Entrada
1 × 40 × 401

→

4 × Conv 3×3, stride 2
+ BatchNorm + ReLU · 16 → 32 → 64 → 128 mapas

→

Média global
128 valores

→

Dense 64
dropout 0.3

→

3 classes
P / U / A

VÊ UM CICLO INTEIRO

Cada neurónio da última camada vê **~310 ms**: S1, sístole e S2 ao mesmo tempo.

PEQUENA E RÁPIDA

O stride 2 reduz a imagem a metade em cada bloco (40 × 401 → 3 × 26). **106 mil parâmetros.**

NÃO DEPENDE DA POSIÇÃO

A média global no fim encontra o sopro esteja onde estiver na janela.

CLASSIFICADOR 2 · RNN

A RNN lê a mesma janela como uma sequência

401 frames
cada um com 40 bandas (10 ms)

→

GRU bidirecional
2 camadas · 64 unidades por direção · dropout 0.3

→

Média no tempo
128 valores

→

3 classes
dropout 0.3

SABE EM QUE FASE ESTÁ

Lê para a frente e para trás: em cada instante sabe o que veio antes e depois no ciclo cardíaco.

COMPARAÇÃO JUSTA

116 mil parâmetros, quase o mesmo que a CNN, com a mesma entrada e o mesmo treino.

SUBSTITUIU A MLP

A MLP (WA 0.648) via só médias e desvios da janela e perdia **quando** acontece cada som.

ESTRATÉGIA DE TREINO

O mesmo treino para os dois modelos

Componente	Escolha
Função de perda	cross-entropy com pesos de classe inversos à frequência
Desequilíbrio	pesos na perda + limiares de decisão afinados para a WA
Otimizador	Adam, learning rate 0.001 constante, weight decay 0.0001
Batch e épocas	128 janelas · até 50 épocas
Early stopping	perda de validação, paciência 8, ficam os melhores pesos
Regularização	dropout 0.3, weight decay, BatchNorm (CNN)
Data augmentation	deslocamento da janela no tempo (até ±2 s) + SpecAugment
Hardware	1 GPU A100 (Deucalion) · ~10 min para os 5 folds

UMA PREVISÃO POR PACIENTE

De janelas de 4 s a uma decisão por criança

Janela
a rede dá P(Present), P(Unknown), P(Absent)

→

Gravação
média das janelas

→

Paciente
máximo entre os focos: basta um com sopro

→

Regra com 2 limiares
Present se P ≥ t1 · senão Unknown se U ≥ t2 · senão Absent

PORQUÊ LIMIARES

A métrica pesa as classes 5 / 3 / 1. Os limiares ajustam a decisão a esses pesos, em vez de escolher só a classe mais provável.

LIMIARES FINAIS

CNN: t1 = 0.50 · t2 = 0.725
RNN: t1 = 0.65 · t2 = 0.70
escolhidos para maximizar a WA, noutros folds

RESULTADOS INTERMÉDIOS

Do 0.65 ao 0.77: o que fez subir o resultado

O modelo e a entrada

MLP com 99 features por janela · **0.648**



perde **quando** acontece cada som

1.ª CNN sobre o espectrograma · **0.724**



5 s, 25–400 Hz, normalização por janela, 8 épocas

CNN final, mesma arquitetura · **0.767**



pré-processamento guiado pela EDA: até 1000 Hz, normalização por banda, 4 s a 10 ms, 50 épocas

A decisão por paciente (mesma CNN)

Regra	WA
média das gravações + classe mais provável	0.703
+ limiares afinados para a WA	0.747 (+0.044)
+ máximo entre focos	0.767 (+0.020)

Na RNN, o mesmo: 0.712 → 0.746 → 0.761.

WA média em validação cruzada. A 1.ª CNN foi medida com o código da altura (31 out.); as mudanças até à final foram feitas em conjunto.

TESTES EXTRA

O que tentámos para melhorar, e porque não ficou

Alteração	Porquê	CNN	RNN	Decisão
Atenção na RNN	focar os instantes com sopro	—	+0.000	rejeitada
Descida da lr (÷10)	curvas de validação ruidosas	−0.011	+0.005	rejeitada
Paragem pela WA	alinhar a paragem com a métrica	−0.015	−0.008	rejeitada
Descida da lr + paragem pela WA	as duas juntas	+0.006	−0.012	rejeitada

REGRA FIXADA ANTES DE VER OS RESULTADOS

Só fica se ganhar **mais de 0.02** de WA e for melhor em **pelo menos 4 dos 5 folds**. Senão, fica a versão mais simples.

O QUE APRENDEMOS

A WA de um fold (~11 Unknown) oscila ±0.03 a 0.05 entre épocas: ganhos menores do que isso são ruído.

Diferenças de WA média em relação ao modelo base (validação cruzada).

RESULTADOS · VALIDAÇÃO CRUZADA (753 PACIENTES)

A CNN e a RNN empatam, muito acima do mínimo de 0.50

CNN · WA (MÉDIA ± DP DOS 5 FOLDS)

0.767 ± 0.021

Recall: Present 0.78 · Unknown 0.33 · Absent 0.87

previsto ↓ · verdadeiro →	P	U	A
Present	112	6	35
Unknown	3	18	36
Absent	28	30	485

RNN · WA (MÉDIA ± DP DOS 5 FOLDS)

0.761 ± 0.037

Recall: Present 0.78 · Unknown 0.24 · Absent 0.88

previsto ↓ · verdadeiro →	P	U	A
Present	112	4	36
Unknown	3	13	28
Absent	28	37	492

RESULTADOS · TESTE FINAL (FOLD −1)

No teste, 189 crianças nunca vistas, os resultados aguentam-se

Modelo	WA na CV	WA no teste	Recall P	Recall U	Recall A
CNN	0.767	0.751	0.78	0.21	0.88
RNN	0.761	0.789	0.81	0.36	0.90

CNN · previsto ↓ · verdadeiro → (P, U, A)

	P	U	A
Present	28	0	9
Unknown	0	3	8
Absent	8	11	122

RNN · previsto ↓ · verdadeiro → (P, U, A)

	P	U	A
Present	29	0	6
Unknown	1	5	8
Absent	6	9	125

A RNN fica à frente por **~6 crianças** (2 delas Unknown, num teste com só 14). Os modelos foram escolhidos antes, pela CV, e **não mudámos nada depois** do teste.

COMPARAÇÃO COM A LITERATURA

Ao nível do vencedor do PhysioNet Challenge 2022

Modelo	Parâmetros	WA (CV)	Recall P / U
CNN (nossa)	106 mil	0.767 ± 0.021	0.78 / 0.33
RNN (nossa)	116 mil	0.761 ± 0.037	0.78 / 0.24
HearHeart, receita completa	38 mil	0.750 ± 0.030	0.78 / 0.17
HearHeart, só a rede com o nosso treino	38 mil	0.715 ± 0.051	0.70 / 0.48
MLP (a nossa 1.ª abordagem)	60 mil	0.648 ± 0.026	0.71 / 0.30

COMPARAÇÃO JUSTA

Reimplementado a partir do código oficial e treinado com os nossos folds e a nossa avaliação.

EMPATE ESTATÍSTICO

CNN − HearHeart = +0.017, IC 95% [−0.016; +0.047] (bootstrap por paciente).

Lu et al., HearHeart (1.º lugar no Challenge 2022). Os números oficiais vêm de outro teste e não se comparam diretamente.

CONCLUSÕES

O que aprendemos, o que falta e o que faríamos a seguir

O QUE APRENDEMOS

CNN e RNN empatam (~0.76): o sopro é um padrão local entre S1 e S2, e a CNN já o vê.

O que fez subir: o **espectrograma** em vez de features (+0.08), o **pré-processamento guiado pela EDA** (+0.04) e a **decisão por paciente** (limiares e máximo, +0.06).

Ao nível do **estado da arte** só com o áudio.

LIMITAÇÕES

Unknown continua difícil (recall 0.21 a 0.36): rótulo ruidoso e poucos exemplos.

Uma só seed por configuração.

O early stopping usa o fold onde se mede a WA: a CV fica ligeiramente otimista (o teste confirma que pouco).

TRABALHO FUTURO

Juntar a CNN e a RNN num **ensemble**.

Várias seeds e um critério de paragem mais estável.

Usar a **segmentação do ciclo** como tarefa auxiliar no treino.

BÓNUS · DADOS ESCONDIDOS

Previsões para 100 crianças que ninguém do grupo ouviu

OS DADOS

100

crianças · 342 gravações · campanha CC2015 · sem rótulos

O MODELO

A **CNN**, escolhida pela validação cruzada. Mesmo pré-processamento, média dos 5 modelos dos folds e os limiares finais.

AS PREVISÕES

32 Present · **5 Unknown** · **63 Absent**

Mais Present do que no treino (32% contra 19%): os limiares favorecem Present, que pesa 5.

Ficheiro entregue: **PL3_G08_test_results.csv** (colunas ID, Murmur), gerado com **python -m src.predict --template ...**

APÊNDICE

Material de apoio para perguntas: a MLP, as curvas de treino, para onde olha a RNN e perguntas prováveis

APÊNDICE · A PRIMEIRA ABORDAGEM

A MLP: 99 números por janela, sem a ordem no tempo

99 features por janela
MFCC (média, desvio, deltas), forma do espectro, energia em 5 bandas, periodicidade

→

256 → 128
ReLU + dropout

→

3 classes
60 mil parâmetros

RESULTADO

0.648

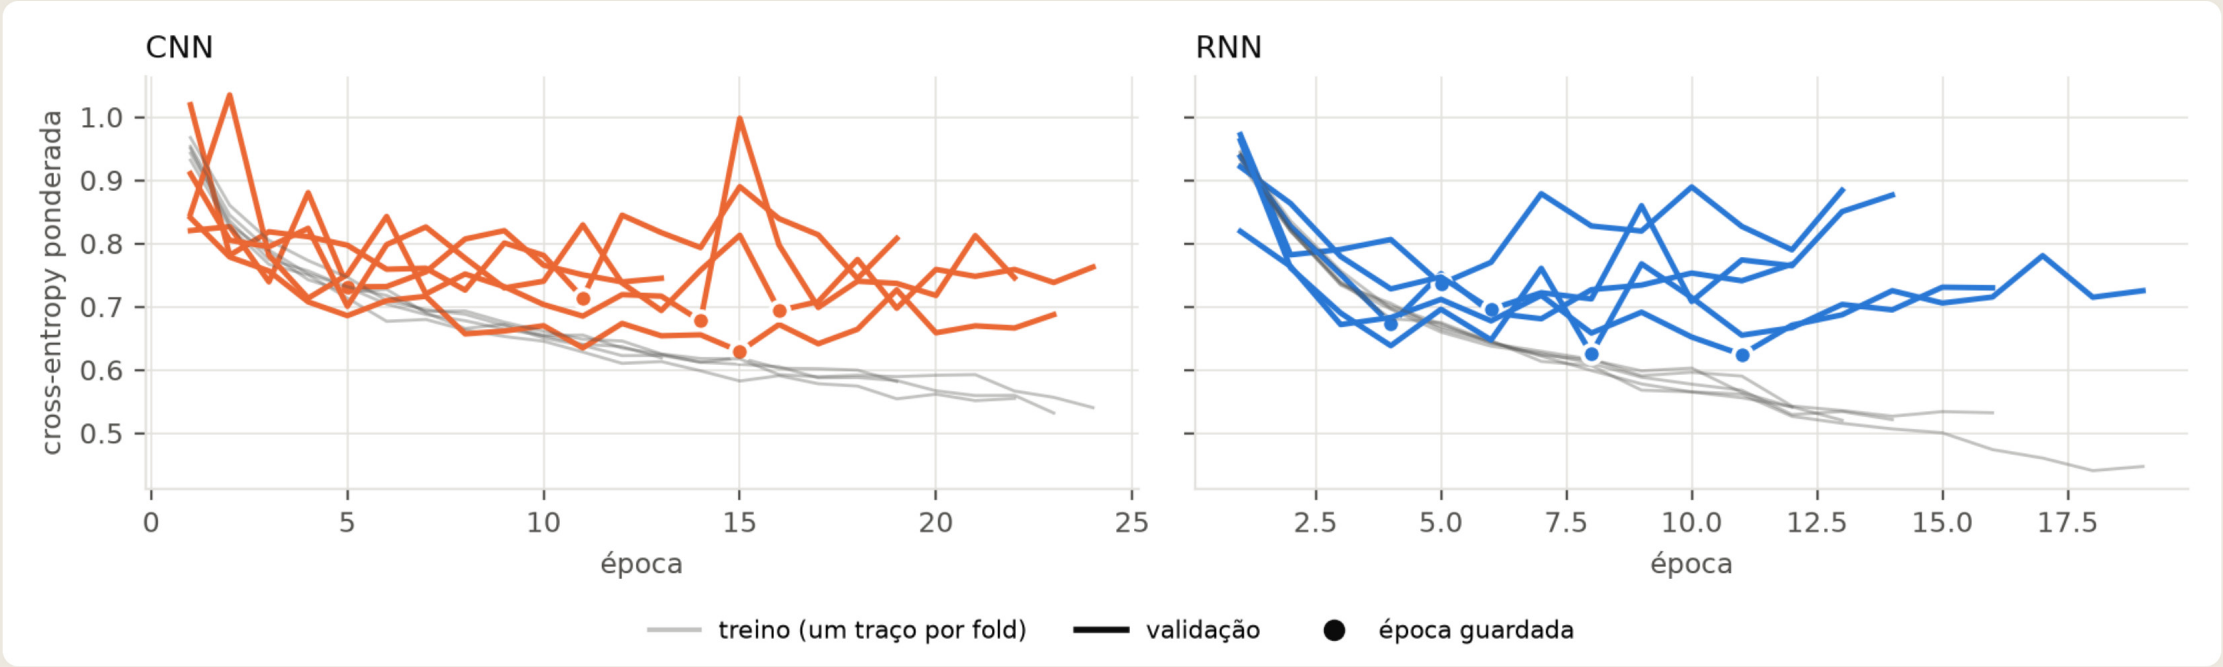
± 0.026 de WA, mesmo protocolo e mesma agregação por paciente

PORQUE FOI SUBSTITUÍDA

Médias e desvios de uma janela de 4 s perdem **quando** a energia aparece. Um sopro define-se por estar entre S1 e S2, e isso só se vê no espectrograma (CNN) ou na sequência (RNN).

APÊNDICE · CURVAS DE TREINO

Os modelos convergem em 5 a 15 épocas



A perda de validação estabiliza cedo; o early stopping (paciência 8) guarda os pesos da melhor época. Por isso a descida da learning rate chegava tarde demais para fazer diferença.

APÊNDICE · METODOLOGIA

Porque não pesquisámos hiperparâmetros, e o early stopping

O RUÍDO É GRANDE

Num fold, **1 criança Unknown** muda a WA em **~0.010**; 1 Present em ~0.017.

As nossas 7 variantes variaram ±0.009. Escolher a melhor de 20 configurações **sem nenhuma melhoria real** daria **+0.016 só por sorte** (simulação).

O QUE DIZ A LITERATURA

Escolher entre muitas configurações com poucos dados sobreajusta à validação, com efeito da ordem das diferenças entre algoritmos (Cawley & Talbot, 2010).

Afinar dentro da CV enviesa a estimativa; o remédio é CV aninhada (Varma & Simon, 2006), que usámos nos limiares.

EARLY STOPPING

Escolhe só a **época**, pela perda de milhares de janelas, não pela WA de ~150 crianças: pouca margem para sorte.

Teste − CV: CNN −0.016, RNN +0.028. **Sem otimismo sistemático visível.**

Cawley & Talbot, JMLR 11, 2010 · Varma & Simon, BMC Bioinformatics 7:91, 2006 · Bouthillier et al., MLSys 2021 · Prechelt, 1998.

APÊNDICE · INTERPRETAÇÃO

Para onde olha a RNN com atenção?

Fase do ciclo	Sem sopro	Com sopro
S1	2.90	3.02
Sístole	0.26	0.44
S2	1.23	0.44
Diástole	0.35	0.51

Lift = fração da atenção numa fase ÷ fração do tempo dessa fase. Acima de 1: mais atenção do que a duração justifica.

A rede ancora-se no **S1**, o som mais forte e regular.

Com sopro, dá **mais atenção à sístole** (0.26 → 0.44) e menos ao S2: olha para onde o sopro está.

APÊNDICE · PERGUNTAS PROVÁVEIS

Respostas curtas

COMO EVITARAM FUGA DE INFORMAÇÃO?

Divisão por paciente, normalização e limiares só com treino, teste usado uma vez.

COMO TRATARAM O DESEQUILÍBRIO?

Pesos de classe na perda e limiares afinados para a WA.

COMO ESCOLHERAM HIPERPARÂMETROS?

Valores padrão fixados antes. Os dados só escolhem épocas, limiares e iterações.

PORQUE É QUE O UNKNOWN É DIFÍCIL?

Não é um som: é “não deu para decidir”. Poucos exemplos e rótulo inconsistente.

PORQUE NÃO FICARAM COM A RNN, MELHOR NO TESTE?

Usar o teste para escolher é proibido. A escolha foi feita antes, pela CV.

PORQUE NÃO TRANSFER LEARNING?

Não há modelos pré-treinados em sons cardíacos; os nossos treinam em ~10 min.

MACHINE LEARNING II · 2026/27 · TURMA PL3 · GRUPO 08

Deteção de sopros cardíacos com uma CNN e uma RNN

Uma previsão por criança (Present / Unknown / Absent) a partir de gravações do coração do dataset CirCor DigiScope

Afonso Miguel Vieira Marcos (202404088) · Pedro Miguel Moreira Pereira Afonso (202404125) · Rafael Arruda Costa (202300278)