Deteção de sopros cardíacos em fonocardiogramas

CNN e RNN sobre o CirCor DigiScope — Machine Learning II

Gerado por `reports/make_report.py`

07/11/2026

Conteúdo

1 Resumo **2**

2 O problema e os dados **2**

3 Pré-processamento e protocolo de avaliação **2**

4 Os dois classificadores **3**

CNN 2D 3

RNN (GRU bidirecional) 4

Estratégia de treino (igual nos dois) 4

5 Iterações: o que mudámos e porquê **4**

6 Resultados **6**

7 Comparação com a literatura **7**

8 Para onde olha a RNN? **7**

9 Conclusões, limitações e trabalho futuro **8**

10 Apêndice — perguntas prováveis na apresentação **9**

1 Resumo

O objetivo é dizer, para cada criança, se tem um sopro cardíaco (*Present*), se não tem (*Absent*) ou se a gravação não permite decidir (*Unknown*), a partir dos sons do coração (dataset CirCor DigiScope). Implementámos os dois classificadores pedidos de entre MLP, CNN e RNN: uma **CNN** e uma **RNN**, que recebem a mesma entrada (o mel-espectrograma de janelas de 4 s) e são treinadas e avaliadas da mesma forma.

	CNN	**RNN**
Como lê o som	procura padrões locais na "imagem" do som	lê o som por ordem, frame a frame
WA (validação cruzada, 5 folds)	**0.767 ± 0.021**	**0.761 ± 0.037**
Recall *Present* / *Unknown* / *Absent*	0.78 / 0.33 / 0.87	0.78 / 0.24 / 0.88

Os dois modelos **empatam** e estão muito acima do valor mínimo a bater (prever sempre *Present*: 0.50). Também comparámos com dois modelos do PhysioNet Challenge 2022, incluindo o vencedor, reimplementados nas mesmas condições: nenhum ganha à nossa CNN.

2 O problema e os dados

- **Dados:** 942 pacientes (0 a 21 anos) e 3163 gravações a 4 kHz, de 5 a 65 s. Em geral há uma gravação por foco de auscultação (aórtico, pulmonar, tricúspide, mitral).
- **O rótulo é do paciente**, não da gravação: 74% *Absent*, 19% *Present*, 7% *Unknown*. Temos de dar **uma previsão por paciente**.
- **O sopro pode ouvir-se só nalguns focos:** 19% das gravações de pacientes *Present* não têm sopro audível. Usamos o campo `Murmur locations` para dar a cada gravação o seu próprio rótulo no treino.
- **Os sopros são quase todos sistólicos** (entre os sons S1 e S2) e fracos, e na sístole há ~5 dB mais energia acima de 150 Hz quando há sopro. O modelo tem de ver ciclos cardíacos completos com boa resolução no tempo.
- ***Unknown* é sobretudo "má gravação":** as gravações *Unknown* são as menos periódicas e as mais ruidosas.

A métrica é a *weighted accuracy* (WA) por paciente: cada *Present* conta 5 vezes, cada *Unknown* 3 e cada *Absent* 1, porque falhar um sopro é pior do que um falso alarme. Prever sempre *Absent* dá só 0.39; prever sempre *Present* dá 0.50, **o valor mínimo a bater**.

3 Pré-processamento e protocolo de avaliação

Decisão	**Porquê**
Filtro passa-banda 25–1000 Hz e normalização da amplitude de cada gravação	abaixo de 25 Hz há movimento; acima de 1 kHz quase só ruído; o volume varia entre estetoscópios
Janelas de 4 s com passo de 2 s (31409 janelas)	as gravações têm durações muito diferentes; 4 s têm 3 a 7 ciclos cardíacos completos
Mel-espectrograma 40 bandas × 401 frames (20–1000 Hz, um frame a cada 10 ms)	10 ms chegam para separar S1, sístole e S2, que é onde está o sopro

Decisão	Porquê
Sem normalização por janela	o nível absoluto em dB ajuda a reconhecer as gravações ruidosas (*Unknown*)
Normalização por banda mel só com os dados de treino de cada fold	evita fuga de informação da validação/teste para o treino
Rótulo por gravação no treino, avaliação sempre por paciente	19% das gravações de pacientes *Present* não têm sopro

De janelas a pacientes. A rede dá probabilidades para cada janela. Fazemos a média por gravação; o paciente fica com o **máximo** de P(*Present*) e de P(*Unknown*) entre as suas gravações (basta um foco com sopro). A decisão é hierárquica, como no Challenge: *Present* se P(*Present*) $\geq$ t1; senão *Unknown* se P(*Unknown*) $\geq$ t2; senão *Absent*. Os limiares t1 e t2 são escolhidos para maximizar a WA.

Divisão dos dados por paciente, estratificada pelo rótulo: 189 pacientes (20 %) formam o **conjunto de teste**, nunca usado para decidir nada; os restantes 753 formam **5 folds** de validação cruzada. As 70 crianças vistas nas duas campanhas de recolha ficam sempre no mesmo fold. Cada modelo é treinado 5 vezes (uma por fold) e reportamos a média ± desvio padrão da WA nos 5 folds. **Os limiares de cada fold são afinados só nos outros 4 folds**, para a estimativa não ser otimista.

Fold	Present	Unknown	Absent	Total
0	29	11	111	151
1	28	11	112	151
2	28	11	111	150
3	29	11	111	151
4	29	10	111	150
teste	36	14	139	189

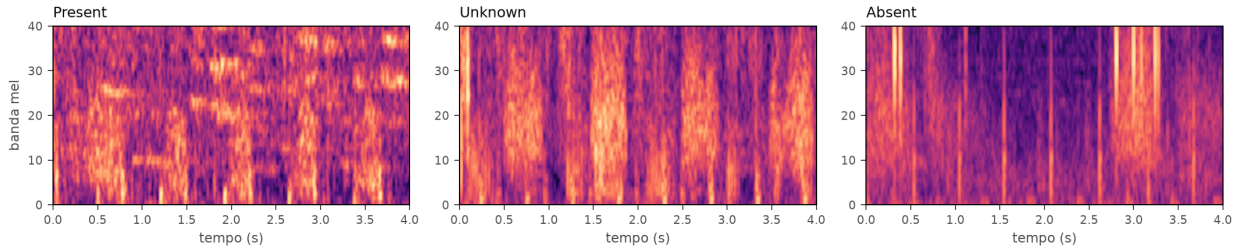


Figura 1: Entrada dos dois modelos: uma janela de 4 s de cada classe (mel-espectrograma normalizado por banda).

4 Os dois classificadores

CNN 2D

Trata o mel-espectrograma como uma imagem. Os filtros convolucionais deslizam pelo tempo e pela frequência e aprendem padrões locais (por exemplo "energia entre S1 e S2").

- 4 blocos `Conv 3×3 (stride 2)` → `BatchNorm` → `ReLU` com 16 → 32 → 64 → 128 mapas. O stride 2 reduz a imagem para metade em cada bloco (40 × 401 → 3 × 26), por isso cada neurónio do último bloco vê ~310 ms: S1 + sístole + S2.

- *Global average pooling* (média de cada mapa) e classificador `Dropout 0.3` → `128` → `64` → `Dropout 0.3` → `3`.
- 106 mil parâmetros.

RNN (GRU bidirecional)

Lê a mesma janela como uma **sequência de 401 frames** (10 ms cada), cada um com as 40 bandas mel. Uma GRU guarda uma memória do que já leu; sendo bidirecional, em cada instante sabe o que veio antes e o que vem depois, ou seja, em que fase do ciclo cardíaco está.

- 2 camadas GRU bidirecionais com 64 unidades por direção, dropout 0.3 entre camadas.
- As saídas dos 401 frames fazem-se a média e passam por `Dropout 0.3` → `Linear` → `3`.
- 116 mil parâmetros, quase os mesmos da CNN, para a comparação ser justa.

A **MLP** (99 features resumidas por janela → 256 → 128 → 3) foi a primeira abordagem (WA 0.648 ± 0.026). Foi substituída pela RNN porque as médias e desvios padrão da janela perdem o **momento** em que a energia aparece, que é o que define um sopro.

Estratégia de treino (igual nos dois)

Função de perda	cross-entropy com **pesos de classe** inversamente proporcionais à frequência (uma janela *Unknown* pesa ~17× uma *Absent*)
Desequilíbrio	pesos de classe na perda + limiares de decisão afinados para a WA
Otimizador	Adam, learning rate 0.001 constante, weight decay 0.0001
Mini-batch / épocas	128 janelas; máximo 50 épocas
Paragem (*early stopping*)	quando a perda de validação não melhora durante 8 épocas; ficam os pesos da melhor época
Regularização	dropout 0.3, weight decay, BatchNorm (CNN)
Aumento de dados	deslocamento aleatório da janela no tempo e *SpecAugment* (uma máscara de frequência e uma de tempo por batch)
Transfer learning	não (testado numa ResNet50 com pesos ImageNet: não funcionou, ver secção 6)
Hardware	uma GPU A100 do Deucalion; ~10 min por modelo para os 5 folds

Como escolhemos os hiperparâmetros. Com ~600 pacientes de treino por fold, procurar muitas combinações na validação cruzada levaria a escolher a que teve sorte nos folds. Por isso fixámos valores padrão antes de treinar (Adam 1e-3, batch 128, dropout 0.3). Os dados só escolhem o número de épocas (early stopping), os limiares (afinados de forma encadeada) e as iterações que ficam (secção seguinte).

5 Iterações: o que mudámos e porquê

Cada alteração partiu de uma observação. **Regra fixada antes de ver os resultados:** uma alteração só fica se aumentar a WA média em mais de 0.02 (cerca de um desvio padrão entre folds) e ganhar em pelo menos 4 dos 5 folds. Caso contrário fica a versão mais simples.

Alteração	Porquê
Atenção na RNN (média ponderada dos frames em vez da média simples)	deixar a rede focar os instantes com sopro
Descida da learning rate (÷10 após 3 épocas sem melhorar)	as curvas de validação eram ruidosas; no modelo vencedor do Challenge a descida da lr foi decisiva
Paragem pela WA por paciente em vez da perda por janela	a perda por janela não está alinhada com a métrica

Modelo	Versão	WA	Δ vs base	Folds a ganhar	Decisão
CNN	base	0.767 ± 0.021	—	—	referência
CNN	+ descida da lr	0.756 ± 0.017	-0.011	1/5	rejeitada
CNN	+ paragem pela WA	0.752 ± 0.034	-0.015	1/5	rejeitada
CNN	+ descida da lr + paragem pela WA	0.773 ± 0.031	+0.006	2/5	rejeitada
RNN	base	0.761 ± 0.037	—	—	referência
RNN	+ atenção	0.762 ± 0.046	+0.000	2/5	rejeitada
RNN	+ descida da lr	0.766 ± 0.046	+0.005	1/5	rejeitada
RNN	+ paragem pela WA	0.753 ± 0.075	-0.008	2/5	rejeitada
RNN	+ descida da lr + paragem pela WA	0.750 ± 0.061	-0.012	2/5	rejeitada

Como interpretámos:

- **Atenção:** não muda a WA, mas mostra para onde a rede olha (secção 7).
- **Descida da lr:** os modelos convergem em 5 a 15 épocas, antes de a descida fazer diferença. Na RNN a lr só desce depois da melhor época.
- **Paragem pela WA:** a WA de um fold é calculada com ~150 pacientes (só ~11 *Unknown*) e oscila ±0.03 a 0.05 de época para época. Escolher o máximo dessa curva escolhe a época com mais sorte: na RNN o desvio padrão entre folds duplica. A perda, calculada sobre milhares de janelas, é um critério mais estável.
- **Nenhuma alteração passou a regra:** os modelos finais são as versões base.

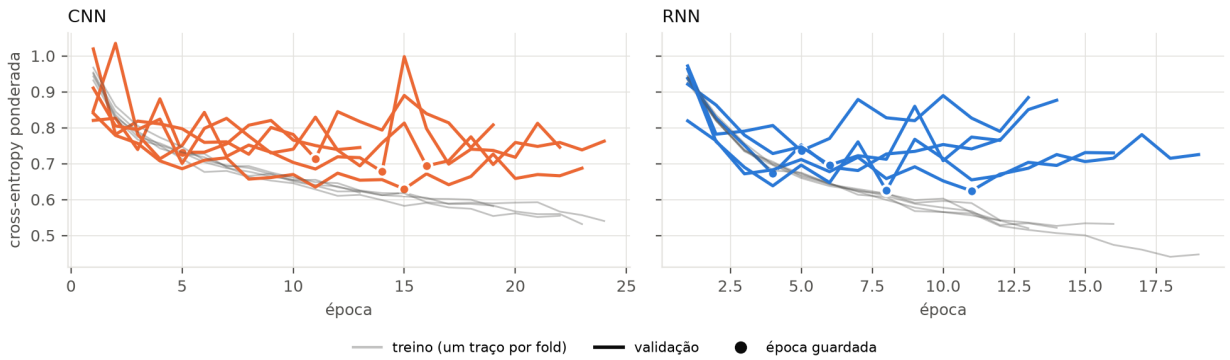


Figura 2: Curvas de treino dos modelos finais: a perda de validação estabiliza ao fim de 5 a 15 épocas e o early stopping guarda a melhor época.

6 Resultados

Validação cruzada com 753 pacientes de desenvolvimento. *WA agregada* junta os 5 folds numa só matriz de confusão. Recall e AUC são métricas adicionais (a AUC mede se o modelo ordena bem os casos, sem depender dos limiares).

Modelo	**WA (média ± dp)**	**WA agregada**	**Recall P**	**Recall U**	**Recall A**	**AUC Present**	**AUC Unknown**
CNN	0.767 ± 0.021	0.767	0.78	0.33	0.87	0.898	0.780
RNN	0.761 ± 0.037	0.761	0.78	0.24	0.88	0.923	0.775

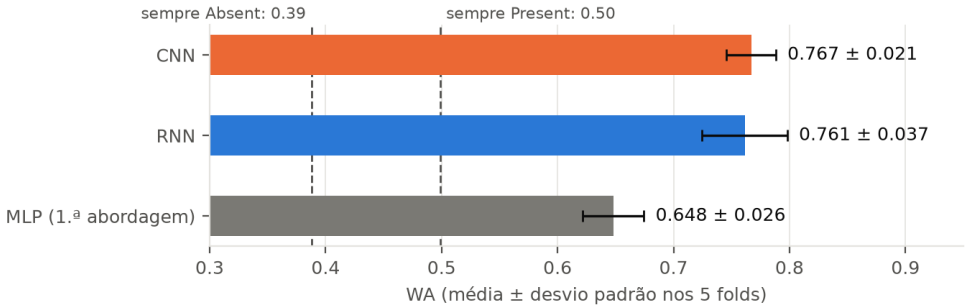
Fold	**CNN**	**RNN**	**RNN − CNN**
0	0.734	0.713	-0.021
1	0.758	0.733	-0.025
2	0.778	0.778	+0.000
3	0.782	0.782	+0.000
4	0.783	0.801	+0.017

CNN (WA agregada 0.767)

previsto ↓ / verdadeiro →	P	U	A
Present	112	6	35
Unknown	3	18	36
Absent	28	30	485

RNN (WA agregada 0.761)

previsto ↓ / verdadeiro →	P	U	A
Present	112	4	36
Unknown	3	13	28
Absent	28	37	492



Leitura.

- **CNN e RNN empatam:** a diferença (-0.006) é menor do que a variação entre folds. Modelar a sequência inteira não acrescenta aos padrões locais da CNN, que já vê S1 + sístole + S2.
- **A RNN distingue melhor os sopros** (AUC *Present* 0.923 contra 0.898) e **a CNN reconhece melhor o *Unknown*** (recall 0.33 contra 0.24).
- ***Unknown* é a classe mais difícil** para os dois. É a mais pequena, é definida por "o médico não conseguiu decidir" (sem um padrão acústico próprio) e vale só ~11 % do peso total da métrica, por isso os limiares tendem a sacrificá-la a favor das outras classes.
- **Limiares finais** (afinados em todos os folds, usados no teste): CNN t1 = 0.500, t2 = 0.725; RNN t1 = 0.650, t2 = 0.700.
- **Teste:** os 189 pacientes de teste ainda não foram avaliados. Avaliam-se uma única vez, com os modelos já fechados (média dos 5 modelos dos folds e os limiares acima).

7 Comparação com a literatura

Para saber se os nossos modelos estão ao nível do estado da arte, reimplementámos dois modelos do PhysioNet Challenge 2022 e treinámo-los **com os nossos folds e a nossa avaliação**, para a comparação ser justa. (Os números publicados no Challenge vêm de um conjunto de teste escondido e não se comparam diretamente.)

- **ResNet50** (Walker et al., 4.º lugar): uma CNN muito profunda, 220× maior do que a nossa. Três versões: só a rede; dividida em dois classificadores binários (*Present* vs resto, *Unknown* vs resto); e com pesos pré-treinados no ImageNet.
- **HearHeart** (Lu et al., 1.º lugar), reimplementado a partir do código oficial: uma CNN ainda mais pequena do que a nossa. Duas versões: só a rede com o nosso treino; e a receita completa deles (segmentos de 15 s, frequências até 2 kHz, descida da lr, pesos de classe 5/3/1).

Modelo	**Papel**	**Parâmetros**	**WA**	**Folds a ganhar à CNN**	**Recall P / U**
CNN	classificador 1	106 mil	0.767 ± 0.021	—	0.78 / 0.33
RNN (BiGRU)	classificador 2	116 mil	0.761 ± 0.037	1/5	0.78 / 0.24
MLP	primeira abordagem	60 mil	0.648 ± 0.026	0/5	0.71 / 0.30
ResNet50	literatura (4.º lugar)	23.5 M	0.756 ± 0.038	1/5	0.84 / 0.15
Dual ResNet50	literatura (4.º lugar)	47.0 M	0.758 ± 0.034	1/5	0.83 / 0.11
Dual ResNet50 ImageNet	literatura (4.º lugar)	47.0 M	0.623 ± 0.069	0/5	0.71 / 0.04
HearHeart, só a rede	literatura (1.º lugar)	38 mil	0.715 ± 0.051	1/5	0.70 / 0.48
HearHeart, receita completa	literatura (1.º lugar)	38 mil	0.750 ± 0.030	2/5	0.78 / 0.17

O que aprendemos:

- **Mais capacidade não ajuda:** as ResNet50 sobreajustam mais cedo (melhor época 3 contra 12 na CNN, em média) e não ganham. O pré-treino no ImageNet falhou: filtros aprendidos em fotografias não servem para estes espectrogramas.
- **A nossa CNN está ao nível do vencedor do Challenge:** a receita completa do HearHeart fica muito perto da CNN (e chega a 0.763 com a regra de decisão deles), mas não a ultrapassa. O ganho deles vem da estratégia de treino e não da rede: com o nosso treino, a rede deles fica pior.

8 Para onde olha a RNN?

Na versão com atenção, a RNN dá um peso a cada frame. Comparámos esses pesos com as segmentações manuais do ciclo cardíaco (usadas só para interpretar, não no treino). *Lift* = fração da atenção numa fase ÷ fração do tempo dessa fase; acima de 1, a fase recebe mais atenção do que a sua duração justificaria.

Fase	Lift, gravações sem sopro	Lift, gravações com sopro
S1	2.90	3.02
sístole	0.26	0.44
S2	1.23	0.44
diástole	0.35	0.51

A rede ancora-se no **S1**, o som mais forte e regular. Nas gravações **com sopro** dá mais atenção à **sístole** ($0.26 \rightarrow 0.44$) e menos ao S2: olha mais para onde está o sopro quando ele existe. Numa GRU bidirecional, o estado no S1 já resume o que vem a seguir, por isso focar o S1 não significa ignorar a sístole.

9 Conclusões, limitações e trabalho futuro

1. **Os dois classificadores funcionam e empatam:** CNN 0.767 ± 0.021 e RNN 0.761 ± 0.037, muito acima do mínimo de 0.50. Para detetar o sopro, os padrões locais da CNN chegam; ler a sequência inteira (RNN) não acrescenta.
2. **O que mais pesou foram as decisões sobre os dados:** rótulos por gravação, janelas com ciclos completos, agregação pelo máximo por paciente e limiares afinados para a métrica.
3. **Os nossos modelos estão ao nível do estado da arte:** nem uma rede $220\times$ maior nem a receita do vencedor do Challenge os ultrapassam nas mesmas condições.
4. **Limitações:** a classe *Unknown* continua difícil (rótulo ruidoso, poucos exemplos); cada configuração foi treinada com uma só seed; não houve pesquisa de hiperparâmetros (de propósito); e o early stopping usa o fold onde depois se mede a WA, o que torna os números de validação ligeiramente otimistas.
5. **Trabalho futuro:** várias seeds por configuração, um critério de paragem mais estável, e usar as segmentações do ciclo cardíaco como tarefa auxiliar no treino.

10 Apêndice — perguntas prováveis na apresentação

Porque é que o rótulo por gravação é diferente do rótulo do paciente? Porque o sopro pode ouvir-se só nalguns focos. Se todas as gravações de um paciente *Present* fossem *Present*, ensinávamos a rede a dizer "sopro" em gravações sem sopro. Na avaliação usamos sempre o rótulo do paciente.

Como passam de janelas para um paciente? Média das janelas por gravação; o paciente fica com o máximo de P(*Present*) e de P(*Unknown*) entre gravações (basta um foco com sopro); depois a regra com dois limiares.

Porque usam limiares em vez da classe mais provável? Porque a métrica pesa as classes de forma diferente (5/3/1). Os limiares ajustam a decisão à métrica. São afinados noutros folds, para não serem otimistas.

Como trataram o desequilíbrio? Pesos de classe na perda (inverso da frequência) e limiares afinados para a WA.

Como evitaram fuga de informação (*data leakage*)? Divisão por paciente (as crianças vistas duas vezes ficam no mesmo fold), normalização calculada só com o treino de cada fold, e o conjunto de teste nunca usado para decidir.

Como escolheram os hiperparâmetros? Valores padrão fixados antes de treinar. Os dados escolhem só as épocas (early stopping), os limiares e as iterações, com uma regra fixada à partida. Procurar muitas combinações com ~600 pacientes por fold levaria a escolher a que teve sorte.

Porque é que a CNN e a RNN dão quase o mesmo? O sopro é um padrão local (entre S1 e S2) e cada neurónio do último bloco da CNN já vê ~310 ms, o suficiente. A RNN vê a janela inteira, mas isso não acrescenta informação útil.

Porque é que o *Unknown* é tão difícil? Não é um som, é "o médico não conseguiu decidir" (ruído, choro, movimento). Tem poucos exemplos, o rótulo é inconsistente (há crianças com rótulos diferentes nas duas visitas) e vale só ~11 % do peso da métrica.

Porque não usaram uma rede maior ou pré-treinada? Testámos: a ResNet50 (220× maior) sobreajusta e não ganha, e o pré-treino no ImageNet falhou.

Quais são os resultados finais? CNN 0.767 ± 0.021 e RNN 0.761 ± 0.037 de WA em validação cruzada; o teste final faz-se uma única vez, no fim.