Deteção de sopros cardíacos em fonocardiogramas (CirCor DigiScope)

Relatório automático — Machine Learning II

Gerado por `reports/make_report.py`

04/11/2026

Conteúdo

1 Análise exploratória **2**

1. Pacientes e rótulos . . . 2
2. Demografia, campanhas e pacientes repetidos . . . 3
3. Como é um sopro? (pacientes *Present*) . . . 3
4. Gravações: número, focos, duração . . . 4
5. Focos com sopro → rótulos por gravação . . . 5
6. Segmentações (.tsv): ciclo cardíaco, frequência cardíaca e energia na sístole . . . 5
7. Exemplos de sinais e conteúdo espectral . . . 6
8. Qualidade do sinal: o que distingue *Unknown*? . . . 7
9. Conclusões para o pré-processamento . . . 7

2 Pré-processamento **8**

1. Decisões de pré-processamento . . . 8
3. Do sinal às entradas dos modelos (uma janela) . . . 9
4. As features da MLP separam as classes? . . . 9
5. Split, desequilíbrio e como usar os dados nos modelos . . . 10

Resumo das decisões para os modelos . . . 10

3 Modelos e resultados **11**

Protocolo de avaliação . . . 11
Modelos . . . 11
Comparação . . . 12
Comentários . . . 13
Teste . . . 14

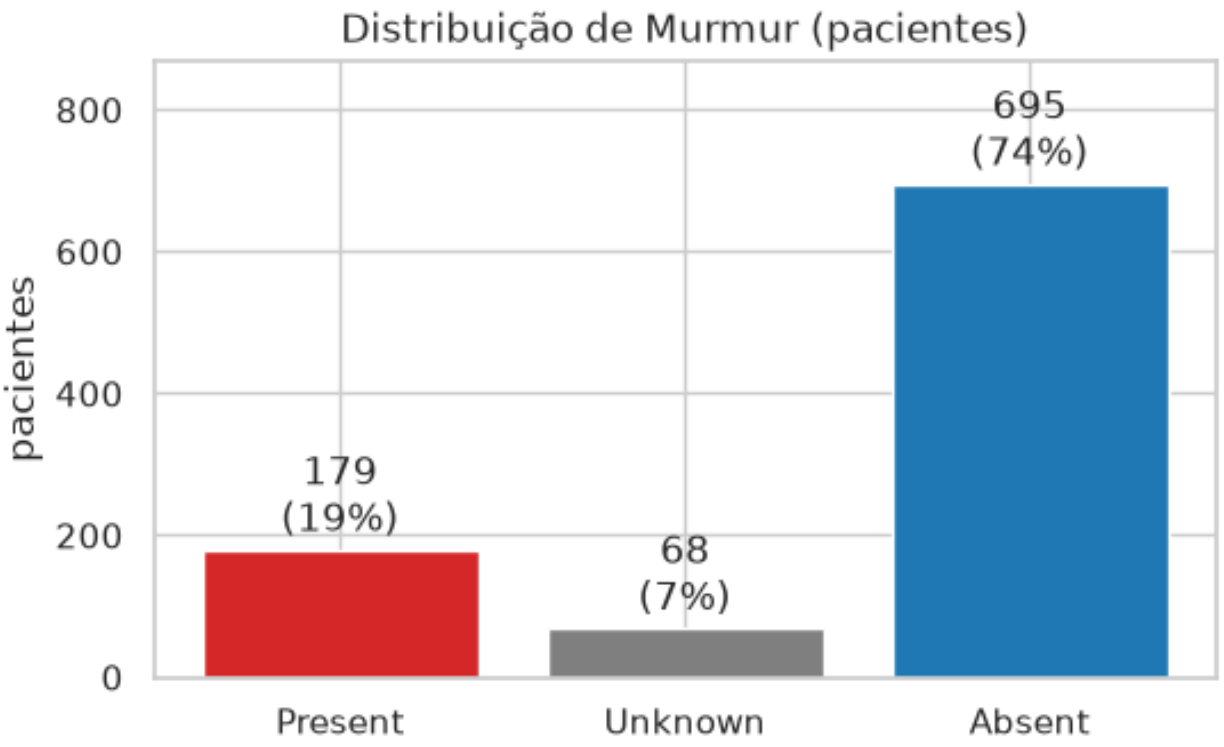
1 Análise exploratória

Objetivo do projeto: prever, **por paciente**, o rótulo `Murmur` (*Present / Unknown / Absent*) a partir dos fonocardiogramas (PCG), avaliado com a *weighted accuracy* do PhysioNet Challenge 2022 (Present ×5, Unknown ×3, Absent ×1).

Diferença face ao projeto UrbanSound8K (`example/`): lá cada clip de ≤4 s tinha **uma** classe (a fonte do som). Aqui o rótulo é do **paciente**, que tem várias gravações longas (uma por foco de auscultação), e o sopro pode ouvir-se só nalguns focos. Por isso esta análise responde a quatro perguntas que determinam o pré-processamento:

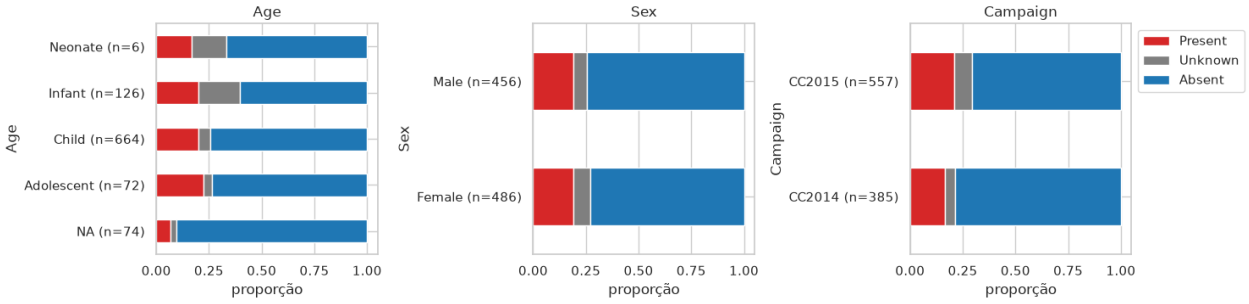
1. Como estão distribuídos os rótulos e que *baseline* temos? (§1–2)
2. Como é um sopro: onde, quando no ciclo cardíaco, que frequências? (§3, §6–7)
3. Que forma têm as gravações: duração, focos, qualidade, *sample rate*? (§4–5, §8)
4. Que consequências tem tudo isto para o pré-processamento? (§9 → implementado em `02_preprocessing.ipynb`)

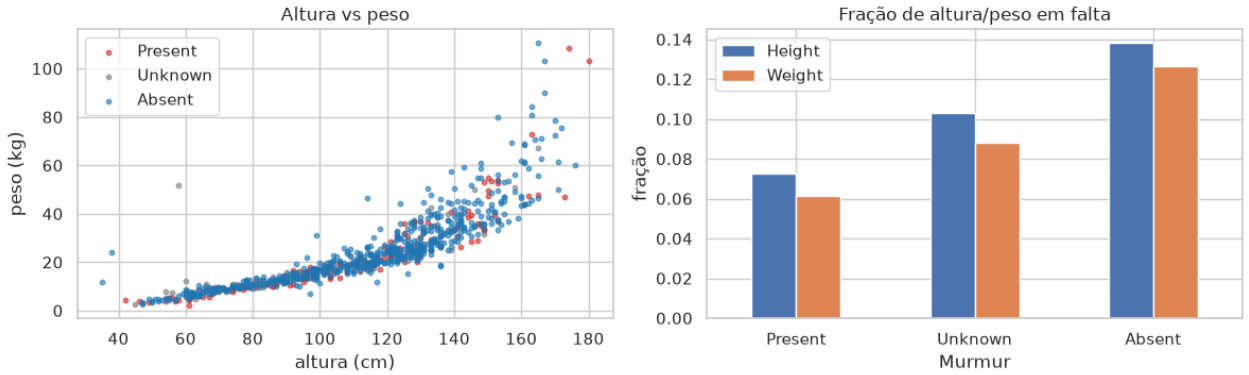
1. Pacientes e rótulos



Leitura. O desequilíbrio é forte (≈74 % *Absent*, 7 % *Unknown*). Com a *weighted accuracy* a lógica inverte-se: prever sempre *Absent* dá só ≈0.39, prever sempre *Present* dá ≈0.50. Este é o valor mínimo que um modelo tem de bater. Na prática, falhar um *Present* custa 5× mais do que um falso alarme, o que justifica pesos de classe na loss e um limiar de decisão afinado na validação.

2. Demografia, campanhas e pacientes repetidos



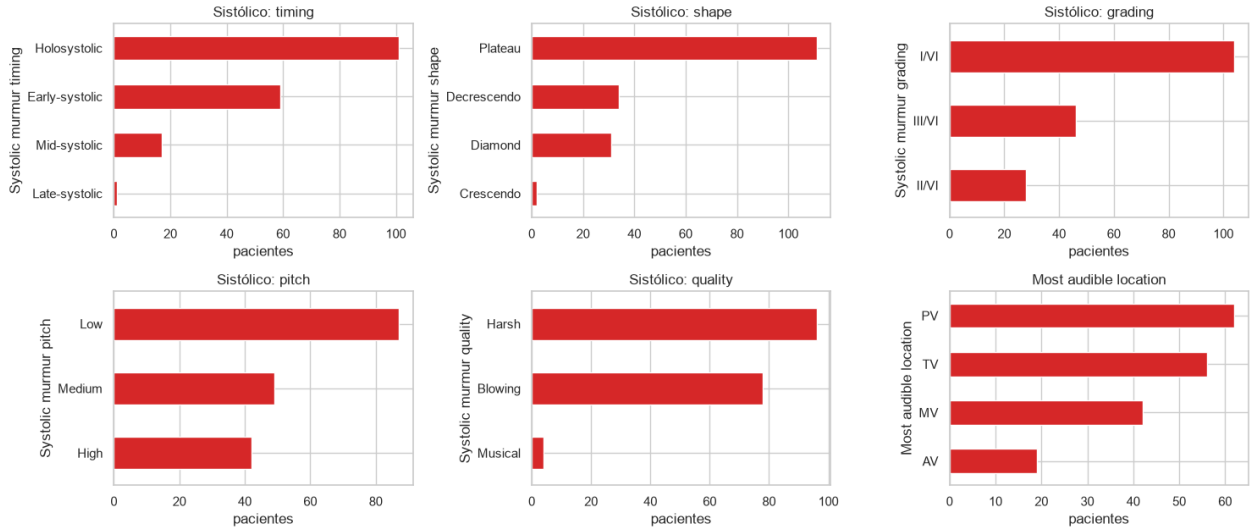


Leitura.

- Os *Infant* têm muito mais *Unknown* (crianças pequenas mexem-se e choram, por isso há mais ruído). A faixa etária explica parte do *Unknown*, mas não usamos a demografia como entrada: o enunciado foca o áudio e a idade falta em ~8 % dos pacientes. Fica como possível extensão.
- A campanha CC2015 tem mais *Present* e *Unknown* do que a CC2014. O split estratificado mantém a proporção global de classes, mas convém ver se os erros se concentram numa campanha.
- Os 140 pacientes com `Additional ID` são 70 crianças vistas nas duas campanhas. Ficam no mesmo fold (já é assim no `split.csv`, verificado em `02_preprocessing.ipynb`). A tabela mostra que o rótulo **nem sempre coincide** entre as duas visitas (cada par aparece duas vezes, uma em cada linha). O próprio rótulo tem ruído, sobretudo à volta de *Unknown*, e isto limita a *accuracy* atingível.

3. Como é um sopro? (pacientes *Present*)

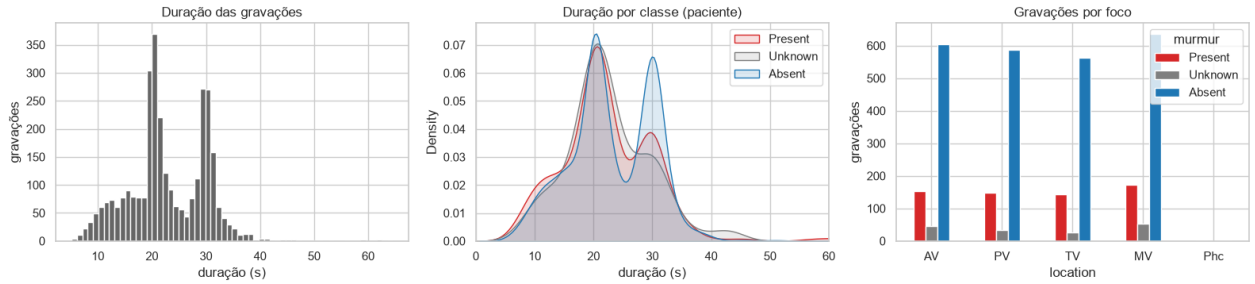
O CSV descreve cada sopro: em que fase do ciclo aparece, a forma, a intensidade (*grading*), o tom e a qualidade. Isto diz-nos que padrão tempo-frequência os modelos têm de encontrar.



Leitura.

- Os sopros são quase todos **sistólicos** (entre S1 e S2). Os diastólicos são raríssimos.
- Predominam *holosystolic* (toda a sístole) e *early-systolic*, de forma *plateau* (intensidade constante), maioritariamente de grau I/VI (**muito fracos**) e de tom *low*, com qualidade *harsh* ou *blowing*. Um sopro típico é um ruído fraco e de banda larga que enche o intervalo entre S1 e S2.
- O foco onde se ouve melhor é sobretudo PV ou TV. AV é o menos frequente.
- Consequência para o modelo: a janela de entrada tem de conter **ciclos cardíacos completos**, para se ver o que se passa entre S1 e S2. Por isso usamos janelas de 4 s em vez de frames curtos (`02_preprocessing.ipynb`). E a resolução temporal tem de ser fina (10 ms) para separar S1/sístole/S2.

4. Gravações: número, focos, duração



Leitura.

- Todas as gravações estão a **4 kHz** (Nyquist 2 kHz), por isso não reamostramos. No UrbanSound8K reamostrámos tudo para 22 kHz.
- A duração varia muito (≈5–65 s, mediana ≈21 s), muito acima dos 4 s fixos do UrbanSound8K. Cortar ou preencher cada gravação para um único tamanho deitaria fora a maior parte do sinal. Em vez disso **partimos cada gravação em janelas de 4 s**: dá uma entrada de tamanho fixo e multiplica o número de exemplos de treino (~10 janelas por gravação).
- A maioria dos pacientes tem os 4 focos (AV, PV, TV, MV). `Phc` é raro (4 ficheiros) e alguns focos estão repetidos (`_1`, `_2`).

- A duração não separa as classes, por isso não é atalho para o modelo.

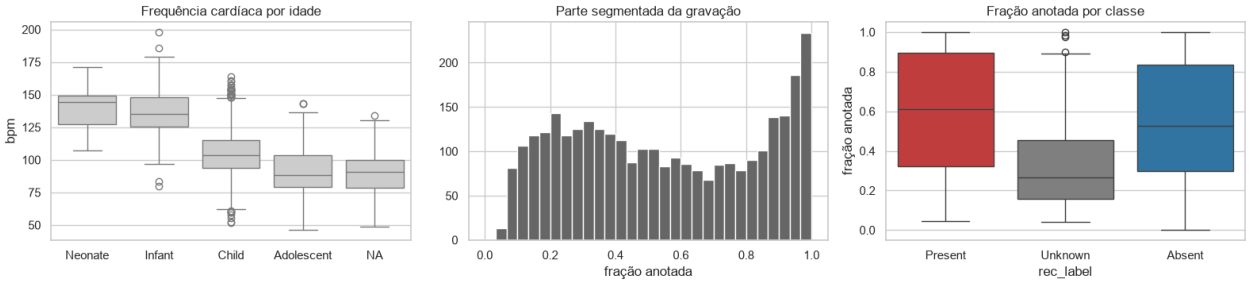
5. Focos com sopro → rótulos por gravação

Num paciente *Present*, o sopro pode ouvir-se só nalguns focos. Se cada gravação herdar o rótulo do paciente, treinamos com rótulos errados (gravações sem sopro marcadas *Present*). O campo `Murmur locations` permite construir um **rótulo por gravação** (`rec_label`, em `src/data.py`): *Present* se o foco está em `Murmur locations`, senão *Absent*. Os pacientes *Unknown*/*Absent* mantêm o rótulo.

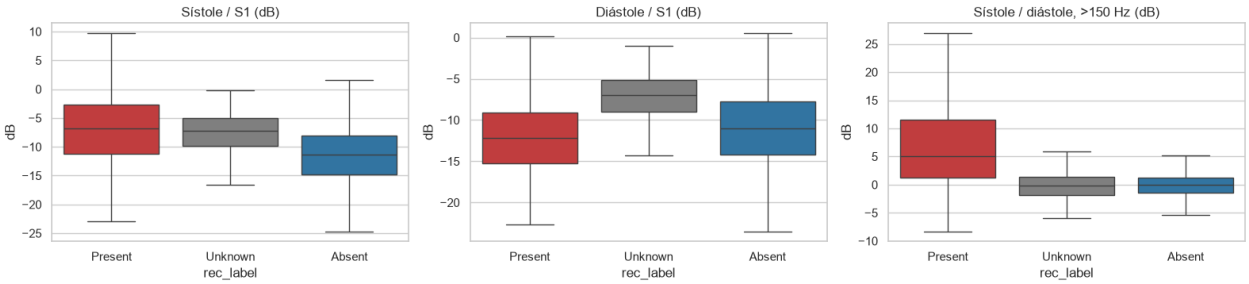
Leitura. Cerca de 1 em cada 5 gravações de pacientes *Present* não tem sopro naquele foco, o que seria ruído no rótulo. Treinamos com `rec_label` e avaliamos sempre com o rótulo do **paciente**. Isto também sugere a agregação por paciente: **basta um foco com sopro** para o paciente ser *Present*, por isso o máximo de P(Present) entre gravações é mais natural do que a média (`aggregate_to_patient(..., how='max_present')`). O sopro ouve-se mais vezes em TV e PV e menos vezes em AV. O foco pode ser uma entrada útil, mas não o usamos por agora.

6. Segmentações (.tsv): ciclo cardíaco, frequência cardíaca e energia na sístole

Cada gravação tem uma segmentação `start, end, state` (0 = não anotado, 1 = S1, 2 = sístole, 3 = S2, 4 = diástole). **Não as usamos como entrada dos modelos**, porque os dados escondidos do bónus podem não as trazer. Servem para perceber o sinal e confirmar que o sopro está onde esperamos.



Agora a pergunta principal: **há mais energia na sístole quando há sopro?** Para cada gravação calculamos a potência média do sinal filtrado (25–1000 Hz) em cada fase. Normalizamos pela potência de S1, o que tira o efeito do volume de cada gravação.

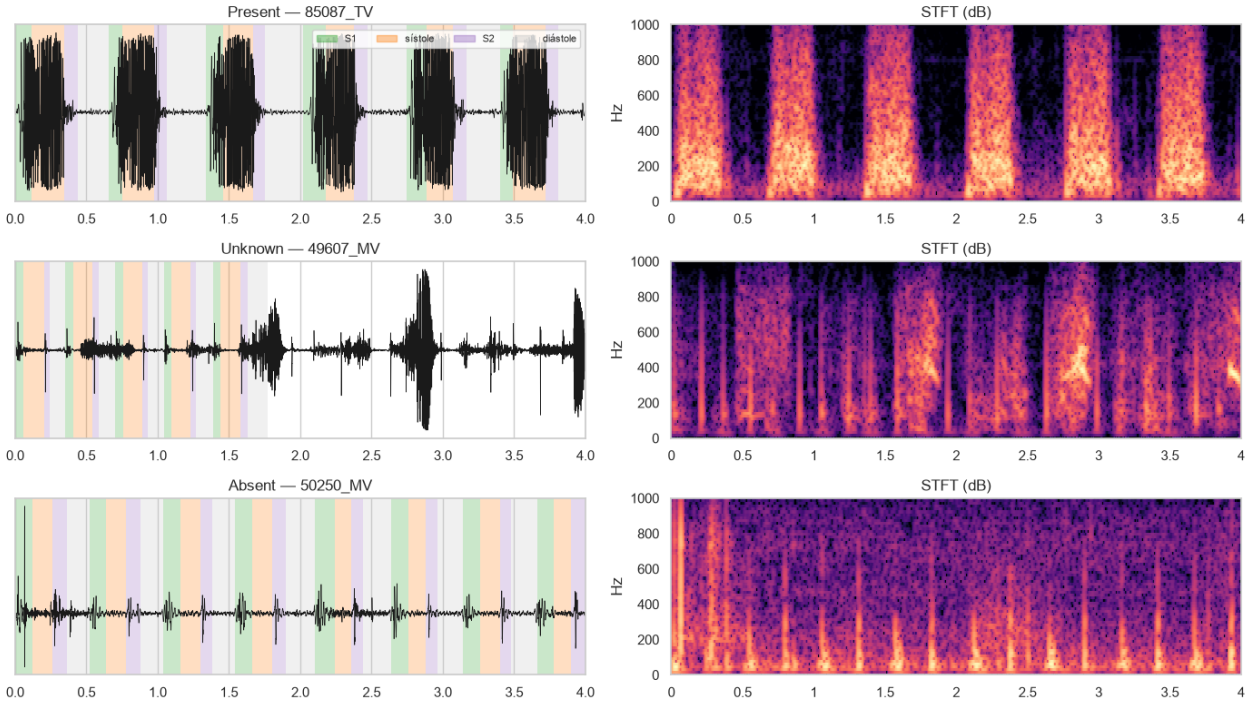


Leitura.

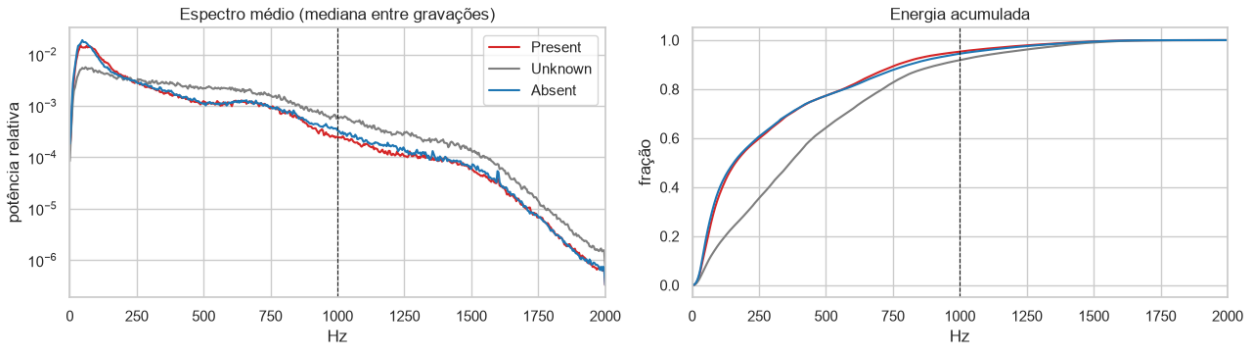
- A frequência cardíaca desce com a idade (mediana ≈ 103 bpm, mínimo 46 bpm). Uma janela de 4 s tem ~**7 ciclos na mediana** e **pelo menos** ~**3** mesmo no batimento mais lento, o que confirma a escolha do tamanho da janela.
- As segmentações cobrem só parte de cada gravação: o anotador segmentou um troço limpo. O resto pode ter mais ruído.

- Nas gravações com sopro a **sístole tem muito mais energia relativa** (face a S1 e à diástole, sobretudo acima de 150 Hz), enquanto a diástole muda pouco. É exatamente o padrão descrito no §3, agora medido no sinal. Logo, uma representação tempo-frequência que mostre o que acontece *entre* S1 e S2 é o que a CNN precisa. Para a MLP, as estatísticas espectrais e de banda captam o mesmo de forma global.

7. Exemplos de sinais e conteúdo espectral



Para cada gravação calculamos o espectro médio (Welch, sinal normalizado) e vemos a média por classe:



Nos exemplos: no *Present* vê-se energia contínua entre S1 e S2 (faixa laranja), ausente no *Absent*. No *Unknown* há ruído forte e irregular que esconde o ciclo (e só parte da gravação foi segmentada).

Leitura.

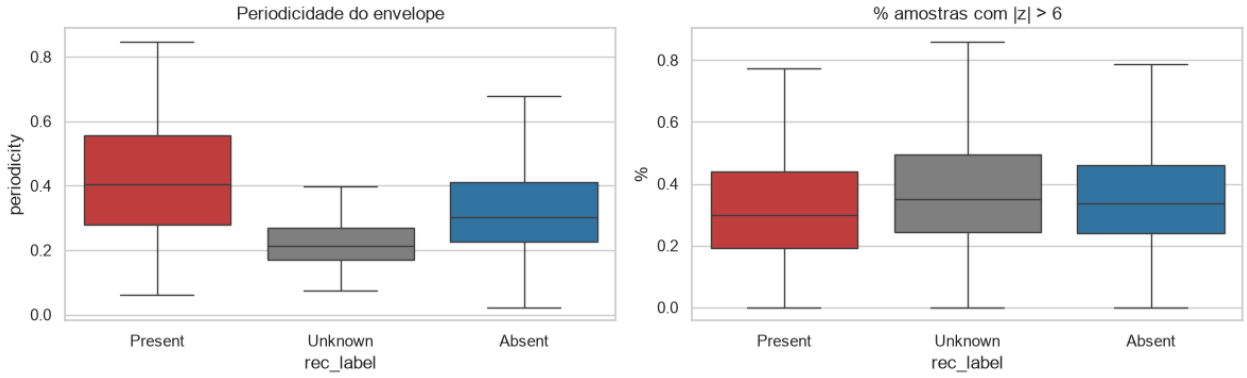
- S1 e S2 concentram-se abaixo de ~150 Hz. Os sopros espalham energia pela sístole até algumas centenas de Hz. Acima de ~1 kHz há sobretudo ruído (fricção, fala, choro).
- Daí o **filtro passa-banda 25–1000 Hz**: abaixo de 25 Hz há deriva e movimento, acima de 1 kHz há pouco sinal útil. Pela mesma razão o mel-espectrograma vai só até 1000 Hz: concentra as bandas mel onde está a informação.

- As gravações *Unknown* têm o espectro deslocado para frequências mais altas, compatível com mais ruído.

8. Qualidade do sinal: o que distingue *Unknown*?

Unknown significa que o médico não conseguiu decidir, muitas vezes por ruído. Duas medidas simples por gravação:

- **periodicidade**: pico da autocorrelação do envelope de energia entre 0.3 e 1.5 s (40–200 bpm). Num som cardíaco limpo é alto; com ruído é baixo.
- **picos/artefactos**: fração de amostras com $|z| > 6$ (pancadas no estetoscópio, cliques).



Leitura. As gravações *Unknown* são menos periódicas, ou seja, o ciclo cardíaco percebe-se pior. Por isso incluímos a periodicidade do envelope nas features da MLP. Na CNN a mesma informação está implícita no espectrograma: a regularidade de S1/S2 ao longo do tempo. Mesmo assim, *Unknown* vai ser a classe mais difícil (é a mais pequena e é definida por "ninguém conseguiu decidir").

Não descartamos gravações ruidosas: o conjunto escondido também as terá e o modelo tem de saber responder *Unknown*.

9. Conclusões para o pré-processamento

O que a exploração decide (implementado em `src/features.py` e `src/prepare_data.py`, demonstrado em `02_preprocessing.ipynb`):

observação (secção)	**decisão**
WA penaliza falhar *Present*; *Absent* domina (§1)	pesos de classe na loss e limiar afinado na validação
a mesma criança nas duas campanhas, rótulos às vezes diferentes (§2)	split por grupo (já no `split.csv`); aceitar um teto de *accuracy*
sopros sistólicos, fracos, entre S1 e S2 (§3, §6)	janelas com ciclos completos e resolução temporal de ~10 ms
tudo a 4 kHz, 5–65 s, ~4 focos por paciente (§4)	sem reamostragem; **janelas de 4 s** (passo 2 s) em vez de crop/pad
~1 em 5 gravações *Present* sem sopro no foco (§5)	treinar com `rec_label`; agregar por paciente com o máximo de P(Present)
frequência cardíaca entre 46 e ~170 bpm, mediana 103 (§6)	4 s chegam para ≥ 3 ciclos (~7 na mediana)
energia útil < 1 kHz, ruído acima (§7)	**passa-banda 25–1000 Hz**; mel até 1000 Hz
Unknown = ruidoso, pouco periódico (§8)	feature de periodicidade na MLP; nível absoluto em dB na CNN (sem min-max)

observação (secção)	decisão
segmentações só cobrem parte e podem faltar nos dados escondidos (§6)	**não usar .tsv como entrada**

2 Pré-processamento

Transforma as gravações em entradas de tamanho fixo para os dois modelos, com as decisões justificadas em `01_eda.ipynb`. O código está em `src/features.py` (configuração e extração), `src/prepare_data.py` (corre tudo e grava em `data/processed/`) e `src/datasets.py` (carregar, normalizar por fold e agregar por paciente). A organização segue a do projeto UrbanSound8K (`example/.../preprocess/`).

1. Decisões de pré-processamento (UrbanSound8K vs CirCor)
2. Gerar os dados processados
3. Do sinal às entradas dos modelos
4. As features da MLP separam as classes?
5. Split, desequilíbrio e como usar os dados nos modelos

1. Decisões de pré-processamento

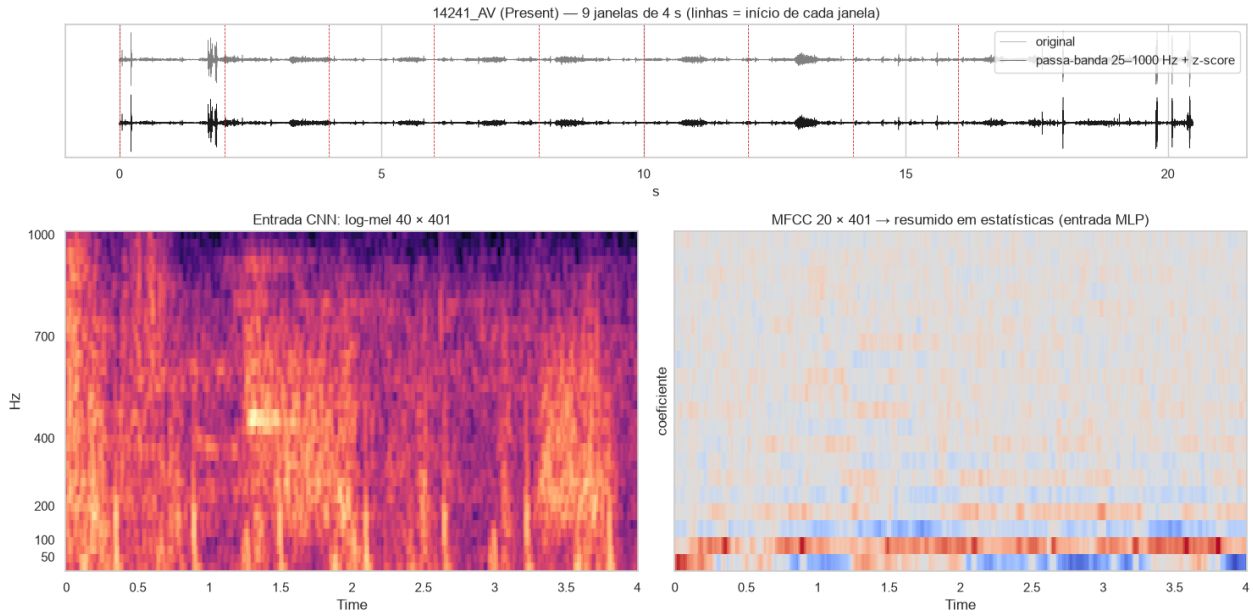
Seguimos a mesma estrutura do projeto UrbanSound8K (`preprocess/config.py`, `features_mlp.py`, `features_cnn.py`, `prepare_data.py`), adaptada ao PCG. O código está em `src/features.py`, `src/prepare_data.py` e `src/datasets.py`.

passo	UrbanSound8K (example)	CirCor (este projeto)	porquê (secção)
sample rate	reamostrar para 22 050 Hz	**4 kHz nativo**	tudo já a 4 kHz, energia < 1.5 kHz (01 §4, §7)
filtragem	—	**passa-banda 25–1000 Hz** (Butterworth 4ª ordem, fase zero)	remove deriva e ruído agudo (01 §7)
amplitude	—	**z-score por gravação**	volumes muito diferentes entre gravações/estetoscópios
duração	crop/pad a 4 s	**janelas de 4 s, passo 2 s**; última janela parcial com pad se ≥ 2 s	gravações de 5–65 s, $\geq$ 3 ciclos por janela (~7 na mediana) (01 §4, §6)
rótulo	classe do clip	`rec_label` por gravação (dos `Murmur locations`)	o sopro pode não estar em todos os focos (01 §5)
MLP	40 MFCC $\times$ (mean, std, Δ, $\Delta\Delta$) = 160	**99 features por janela**: 20 MFCC (mean, std, std Δ, std $\Delta\Delta$) + 6 descritores espectrais (mean, std) + energia em 5 bandas + periodicidade do envelope	sopro = energia de banda larga na sístole (01 §6), *Unknown* = pouco periódico (01 §8)

passo	UrbanSound8K (example)	CirCor (este projeto)	porquê (secção)
CNN	mel 128 × 174, min-max [0,1] por amostra	**log-mel 40 × 401** (n_fft 256 = 64 ms, hop 40 = 10 ms, 20–1000 Hz), em dB sem min-max	resolução temporal para S1/sístole/S2 (01 §3); o nível absoluto ajuda a detetar ruído
normalização	por fold, só treino	**por fold, só treino**: z-score por feature (MLP) e por banda mel (CNN)	sem *data leakage*
previsão final	1 por clip	janelas → gravação → **paciente**	1 previsão por paciente (enunciado)

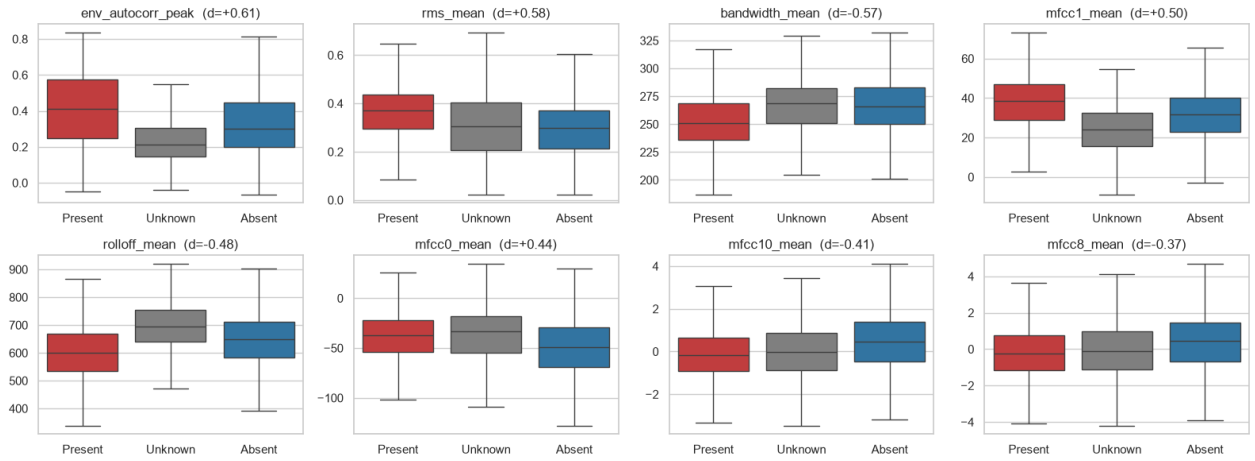
Os dados guardados não têm nenhuma normalização ajustada aos dados, por isso podem ser gerados uma vez para todos os folds.

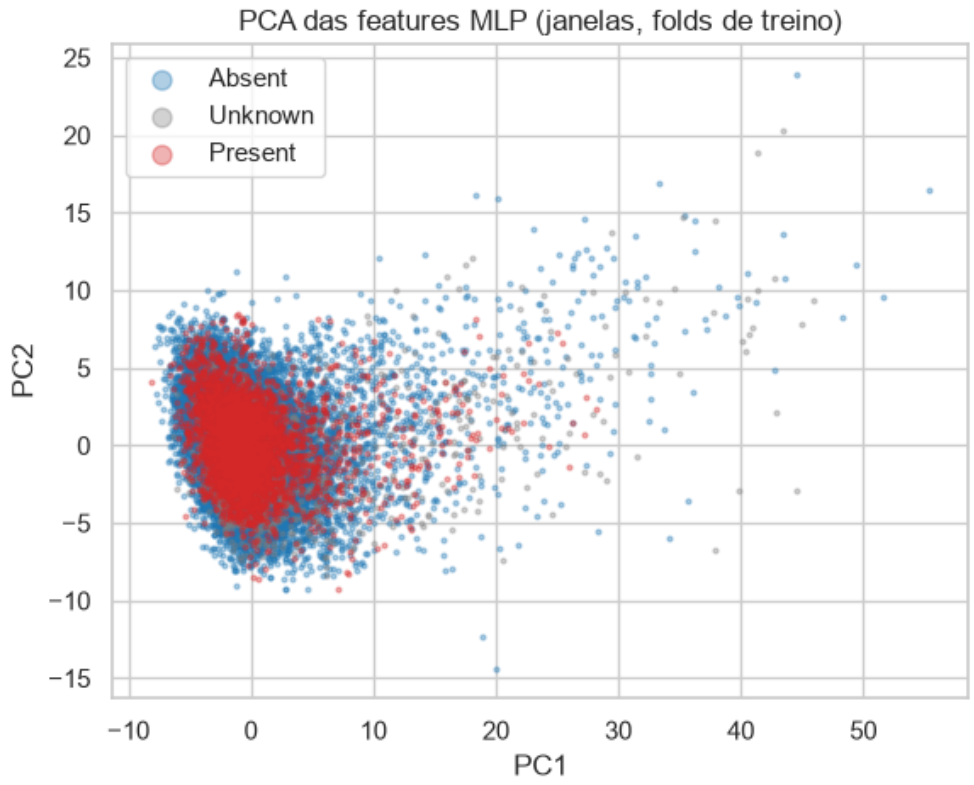
3. Do sinal às entradas dos modelos (uma janela)



4. As features da MLP separam as classes?

Antes de treinar, verificamos se as features escolhidas têm sinal: distribuição de algumas features por classe e uma PCA. Usamos só os folds de treino, para não olhar para o teste.





Leitura. As features espectrais e as estatísticas dos MFCC mudam de forma consistente entre *Present* e *Absent*, mas as classes sobrepõem-se muito na PCA. Nenhuma feature sozinha resolve o problema, por isso faz sentido um modelo não linear. A sobreposição ao nível da janela também é esperada: mesmo num foco com sopro, uma janela ruidosa pode não o mostrar. Agregar várias janelas e focos por paciente compensa isto.

5. Split, desequilíbrio e como usar os dados nos modelos

Resumo das decisões para os modelos

Entradas (geradas por `python -m src.prepare_data`, em `data/processed/`)

- MLP: `X_mlp.npy`, um vetor de 99 features por janela de 4 s. Normalização z-score com a média e o desvio do treino (`mlp_arrays`).

- CNN 2D: log-mel 40 × 401 por janela, cortada de `mel.npy` em tempo real (`CNNWindows`, ou `cnn_arrays` para tudo em memória), normalizada por banda mel com estatísticas do treino. Com `random_crop=True` cada época vê cortes diferentes (*time-shift augmentation*). Também se podem acrescentar SpecAugment (máscaras de tempo/frequência) e ruído gaussiano, como no UrbanSound8K.

Protocolo (`splits/split.csv`, por paciente e estratificado)

- 20 % dos pacientes ficam no teste (fold −1), que **só** se usa para os números finais.
- 5 folds de validação cruzada nos restantes 80 %, para escolher arquitetura, early stopping, limiares e agregação.

Desequilíbrio

- Cross-entropy com pesos de classe (`class_weights`), eventualmente combinada com os pesos da métrica (5/3/1).
- Limiar de decisão afinado na validação para maximizar a *weighted accuracy*.

Uma previsão por paciente (`aggregate_to_patient`)

- As probabilidades das janelas fazem-se a média por gravação.
- Para o paciente, a opção `max_present` usa a gravação com maior P(Present): basta um foco com sopro (01 §5). A alternativa `mean` faz a média de todas as janelas. A escolha entre as duas faz-se na validação.
- Regra a experimentar (como no Challenge): *Present* se algum foco passar o limiar; senão *Unknown* se P(Unknown) for alta; senão *Absent*.

3 Modelos e resultados

Protocolo de avaliação

Divisão por paciente (as crianças vistas nas duas campanhas ficam no mesmo grupo), estratificada pelo rótulo. 20 % dos pacientes formam o conjunto de teste, usado só para os números finais. Os restantes formam 5 folds de validação cruzada: cada modelo é treinado 5 vezes, e cada paciente de desenvolvimento recebe uma previsão do modelo que não o viu. A previsão por paciente é a média das janelas por gravação seguida do máximo entre gravações de P(Present) e P(Unknown), com a regra hierárquica *Present* → *Unknown* → *Absent*. Os limiares de cada fold são escolhidos nos outros 4 folds.

Fold	Present	Unknown	Absent	Total
0	29	11	111	151
1	28	11	112	151
2	28	11	111	150
3	29	11	111	151
4	29	10	111	150
teste	36	14	139	189
total	179	68	695	942

Modelos

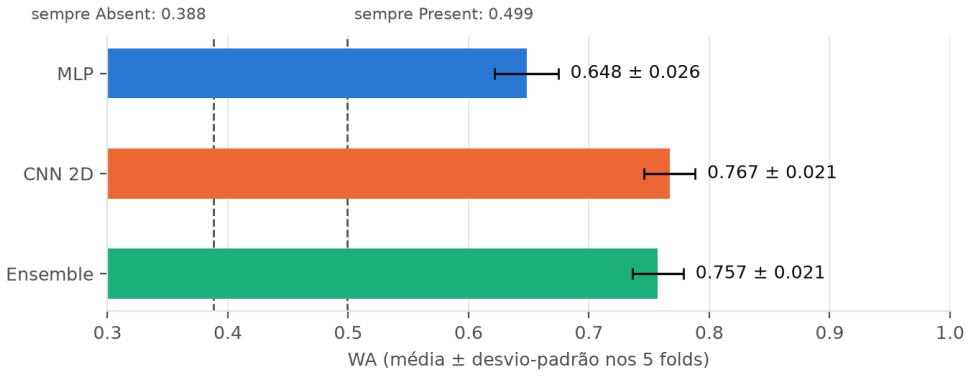
- **MLP**: 99 features por janela de 4 s → 256 → 128 → 3 (BatchNorm, ReLU, dropout 0.3); cross-entropy com pesos de classe, Adam, early stopping na loss de validação.

- **CNN 2D**: log-mel 40×401 por janela, normalizada por banda com estatísticas do treino; 4 blocos Conv 3×3 com stride 2 (16–128 mapas), *global average pooling*, cabeça 128 → 64 → 3; deslocamento temporal aleatório e SpecAugment; mesma loss, otimizador e paragem.
- **Ensemble**: média ponderada das pontuações por paciente; o peso e os limiares são escolhidos sem ver o fold avaliado.

Comparação

Validação cruzada com 753 pacientes de desenvolvimento. *WA (média ± dp)* é a média dos 5 folds; *WA agregada* junta as previsões dos 5 folds numa só matriz de confusão. Os recalls são métricas adicionais.

Modelo	WA (média ± dp)	WA agregada	Recall P	Recall U	Recall A
MLP	0.648 ± 0.026	0.648	0.71	0.30	0.68
CNN 2D	0.767 ± 0.021	0.767	0.78	0.33	0.87
Ensemble	0.757 ± 0.021	0.757	0.78	0.31	0.86



WA por fold

Fold	MLP	CNN 2D	Ensemble
0	0.668	0.734	0.734
1	0.618	0.758	0.737
2	0.630	0.778	0.768
3	0.682	0.782	0.765
4	0.643	0.783	0.783

Matrizes de confusão por paciente (linhas: previsto; colunas: verdadeiro)

MLP

	P	U	A
Present	101	8	155
Unknown	7	16	25
Absent	35	30	376

CNN 2D

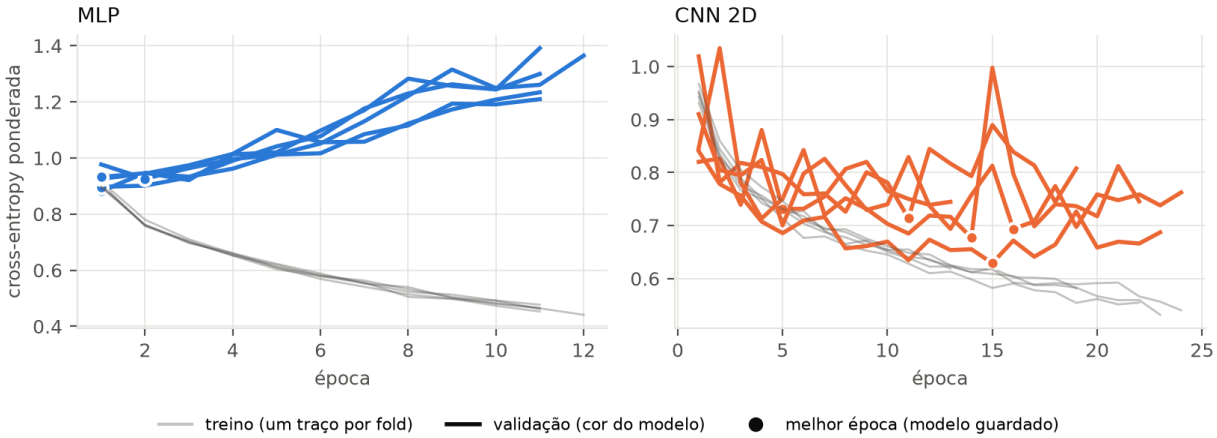
	P	U	A
Present	112	6	35
Unknown	3	18	36
Absent	28	30	485

Ensemble

	P	U	A
Present	111	6	44
Unknown	3	17	33
Absent	29	31	479

Treino

Modelo	Épocas treinadas (fold 0–4)	Melhor época (fold 0–4)
MLP	11, 11, 11, 12, 11	1, 1, 1, 2, 1
CNN 2D	19, 13, 22, 23, 24	11, 5, 14, 15, 16



Comentários

- O melhor classificador individual é a **CNN 2D**, com WA 0.767 ± 0.021.
- A MLP fica 0.119 abaixo (0.648 ± 0.026), uma diferença maior do que a variação entre folds, por isso consistente.
- Todos os modelos ficam acima das regras triviais (sempre *Present*: 0.499; sempre *Absent*: 0.388); o pior fica +0.149 acima da melhor delas.
- O ensemble (peso da CNN escolhido por fold sem ver o fold avaliado; média 0.90) obtém 0.757 ± 0.021, 0.010 abaixo do melhor modelo individual: combinar com a MLP não acrescenta informação útil.
- Em todos os modelos a classe com pior recall é *Unknown* (MLP: 0.30, CNN 2D: 0.33, Ensemble: 0.31). É a classe mais pequena e é definida por o médico não ter conseguido decidir, por isso o rótulo é ruidoso (ver a inconsistência entre visitas da mesma criança na análise exploratória).
- Na CNN 2D, o erro que mais pesa na métrica é prever *Absent* quando o verdadeiro é *Present* (28 pacientes).
- A MLP atinge a melhor loss de validação logo na época 1 (mediana dos folds): a loss de validação sobe desde o início enquanto a de treino desce. Há sobreajuste rápido e o critério de paragem (loss por janela) não está alinhado com a WA por paciente; é o primeiro ponto a melhorar neste modelo.
- A CNN 2D melhora durante várias épocas (melhor época entre 5 e 16) antes de o early stopping parar o treino.
- Estes valores vêm da validação cruzada: o early stopping usou o mesmo fold onde a WA é medida, por isso são ligeiramente otimistas. O número final a reportar é o do conjunto de teste (fold −1), avaliado uma única vez.

Teste

O conjunto de teste ainda não foi avaliado: só se avalia uma vez, depois de fechadas todas as decisões sobre os modelos.